机器人操作的流式任务理解、失败诊断与分层纠错

机器人操作的流式任务理解、失败诊断与分层纠错

一、背景与动机

机器人在真实环境中执行操作任务时，可能出现抓取失败、物体滑落、位置偏差或操作顺序错误等问题。及时理解任务进度、发现异常并提出纠正建议，是提高机器人可靠性的重要环节。

在实际部署中，机器人相关信息随时间持续到达，包括相机图像、末端执行器位姿、关节状态、夹爪状态及控制指令等。系统需要结合当前与历史信息，判断动作是否达到预期效果。例如，夹爪闭合并不一定意味着抓取成功，还需要结合物体是否随末端移动、夹爪开合程度等信息进行判断。同时，持续保存并反复处理全部历史数据，会带来不断增长的存储和计算开销。

发现失败后，系统还需要在不同层次提出纠正建议：既要指出末端移动方向、夹爪动作等具体执行调整，也要判断是否需要回退任务阶段、调整操作顺序或重新规划子目标。

本课题关注：**如何在有限记忆和计算预算下，利用真机部署中持续到达的信息理解机器人操作过程，尽早发现失败征兆或已经发生的失败，并同时给出高层任务规划与低层动作执行两个层次的纠正建议？**

关键词：流式理解、机器人操作、失败诊断、分层纠错、多模态感知、记忆机制。

二、任务目标

设计并实现一个面向机器人操作的在线监测与诊断系统。

- **输入：**任务指令，以及随时间到达的机器人观测与执行信息。可根据数据条件选择图像、EEF 位姿、关节位置与速度、夹爪状态、力／力矩、控制指令等信息中的一种或多种。
- **历史信息：**允许保存有限容量的历史观测、特征或结构化状态，具体记忆机制由学生设计。
- **输出：**当前任务进度与执行状态，并在需要时主动给出失败判断、诊断依据，以及相互对应的高层任务调整建议和低层动作纠正建议。

系统在任意时刻只能使用当时已经获得的信息，历史选帧、特征提取、记忆更新与判断过程均需遵守这一时间约束。

1. 构建流式输入与基线方法

数据可以使用 **ViFailback 等相关开源机器人操作数据集**，根据实际提供的模态选取部分任务，通过按时间顺序回放数据模拟真实部署中的连续观测。

实现以下基础方法之一：

- **当前观测基线：**仅使用当前时刻的观测与任务指令。
- **滑动窗口基线：**使用当前观测及最近一段时间的历史信息。
- **改进方法：**自行设计有限记忆、状态跟踪或响应策略等。

2. 实现任务进度理解与失败诊断

结合任务指令、历史观测与执行信息，跟踪当前操作阶段及关键状态，例如“正在接近物体”“尝试抓取”“搬运中”“正在放置”。

判断动作是否达到预期效果，在出现充分证据时主动发出失败提醒，并说明观察到的问题及判断依据。证据不足时允许继续观察，研究如何减少误报、漏报与重复提醒。

3. 生成高层与低层纠正建议

根据当前任务状态、历史执行过程与失败原因，**同时生成以下两个层次的建议：**

- **高层建议（High-level）：任务理解与规划调整。** 判断当前子任务及其前置条件是否满足，分析失败对后续任务的影响，提出重新尝试、回退阶段、调整操作顺序、更换操作策略或重新规划子目标等建议，说明“接下来应该做什么，以及为什么”。
- **低层建议（Low-level）：具体动作与执行调整。** 将高层建议落实为当前可执行的操作，例如末端向哪个方向移动、如何调整姿态、何时打开或闭合夹爪，说明“具体应该怎样做”。方向应注明参考坐标系。

两层建议应保持一致：高层建议明确恢复任务所需的子目标，低层建议给出实现下一子目标的具体动作，并说明完成后需要检查的状态。

4. 对比实验与效果分析

在基线基础上提出至少一种改进，并从以下维度进行评价：

- **检测效果：**失败检测的 Precision、Recall、F1，以及正常操作过程中的误报情况。
- **响应及时性：**相对人工标注的首次可检测时刻，系统实际发出提醒的延迟，同时报告漏检情况。
- **诊断与建议质量：**诊断是否符合当前证据；高层建议是否合理调整任务与子目标；低层建议是否具体、方向明确且适用于当前状态；两层建议是否一致。
- **计算效率：**实际处理耗时、模型调用次数、输入数据量及记忆占用。

比较不同方法时，应明确数据模态、骨干模型、历史容量与推理预算，并通过消融实验分析新增模态或模块的贡献。已有失败关键帧标注不一定对应首次可检测时刻，可在小规模评测集上补充相应时间标注。

参考文献

[1] Xianchao Zeng, Xinyu Zhou, Youcheng Li, Jiayou Shi, Tianle Li, Liangming Chen, Lei Ren, and Yong-Lu Li. Diagnose, correct, and learn from manipulation failures via visual symbols. In

Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 42386–42395, 2026.

[2] Jiaer Xia, Peixian Chen, Mengdan Zhang, Xing Sun, and Kaiyang Zhou. Streaming video instruction tuning. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 31219–31229, 2026.

[3] Bo He, Hengduo Li, Young Kyun Jang, Menglin Jia, Xuefei Cao, Ashish Shah, Abhinav Shrivastava, and Ser-Nam Lim. MA-LMM: Memory-augmented large multimodal model for long-term video understanding. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 13504–13514, 2024.